

《GeoViewMiner-SAM2》独立预审报告

基于 latex-paper-review 工作流的代码与证据审查

2026 年 8 月 23 日

审查范围与结论

本报告完整检查了 `main5.tex` 的摘要、引言、相关工作、数据集、全部数学公式、实验、讨论、结论及参考文献，并重点将 PromptMiner-SAM2 的方法表述与本地 R1-C4-RD/P2 实现逐项对照。代码核查覆盖粗掩码解码、P2BoundaryRefiner、2P2N 点挖掘、dense prompt rasterization、PromptEncoder/MaskDecoder 数据流、损失归一化、训练参数和现有评估清单。未进行联网检索；依赖外部论文或数据集事实的判断均标为“需核对/确认”。本次审查未修改论文或模型代码。

总体上，单流方法的主要公式已经相当接近实际实现。尤其是 P2 路径的 $64 \rightarrow 32 \rightarrow 64$ 尺度链、 $[-0.4, 0.4]$ 残差界、预测边界支持、目标边界仅进入损失支持、coarse BCE+Dice、点提示的形态学距离以及 dense prompt 门控，均未发现会改变算法含义的核心公式错误。摘要、表格和正文中已经给出的数值差值也都算术正确。

但是，论文目前仍不宜按最终稿提交。最关键原因是主结果和消融结果尚未形成可追溯的已完成实验闭环：当前本地“paper”全量训练仍在第 42/100 轮运行，现有清单中没有论文所报 WHU 测试结果；与此同时，论文中的 WHU 数据规模与运行日志直接冲突。下列问题按严重性排序。

Critical Issues

C-01 主结果与消融结果尚无已完成运行产物支撑

位置：摘要第 34 行；论文表 III 对应源码第 462–491 行；论文表 V 对应源码第 527–546 行；结论第 577 行。

问题：论文将 PromptMiner-SAM2 的 WHU 测试集结果写为 bbox AP 0.749、segm AP 0.735，并进一步报告四行消融结果。审查时，本地用于论文的全量 P2 训练日志仍停留在第 42/100 轮，进程尚在运行；其当前最佳验证 segm AP 约为 0.7093。当前可见的已完成 R1-C4-RD 测试清单报告 segm AP 0.6839，而最新 P2 checkpoint 的验证集 P2-on/off 诊断分别为 0.709304 与 0.709296。本地未发现能够追溯到论文 0.735/0.944/0.855 以及四行消融数据的测试集 `metrics.json/run_manifest.json`。

影响：这不是数值高低问题，而是核心结论的证据链尚未闭合。论文目前的“最高 mask AP”、相对 RSPrompter 的差值、P2 的 0.005 增益、摘要和结论均依赖这些尚不可复核的数字。若这些数字是待完成实验的预留值，则当前稿件的主要实证结论尚未成立。

建议修改：等全量训练、验证选模和一次性测试全部完成后，再从同一组不可变的运行清单自动回填表格。每个表格行至少保存 checkpoint 哈希、架构指纹、数据标注文件哈希、训练命令、选择轮次、测试指标及随机种子。消融四行也应各自对应独立、可核验的最终运行产物；在此之前应将相关数字明确标为占位结果，不能作为投稿结论。

严重性: Critical **确定性:** 确定错误 (就当前本地证据状态而言)

Evidence Chain: “PromptMiner-SAM2 达到 segm AP 0.735” → 论文表 III/表 V → 全量训练与验证选模 → 测试运行清单; 最后一环目前缺失, 且训练仍在进行。

Major Issues

M-01 WHU 数据规模与实际训练日志冲突

位置: 实验数据集, 第 422 行; 当前全量训练日志初始化部分。

问题: 论文称 WHU 共 5,640 张图像, 划分为 2,793/627/2,220。当前全量运行日志明确显示训练集加载 2,943 张、验证集 627 张; 再加测试集 2,220 张, 总数为 5,790 而不是 5,640。训练配置确实指向 2.4annotation/annotation/train.json, 因此不是论文所写数字的简单日志标签差异。

影响: 训练集增加 150 张会影响与文献结果的可比性, 也会使“完整训练集”“同一协议”等表述产生歧义。审稿人无法判断实际采用的是哪个 WHU 实例化版本或是否做过重划分。

建议修改: 直接统计最终提交实验使用的三个 COCO 标注文件, 报告图像数、实例数和文件哈希; 将正文改成与实际运行完全一致的数字。若 2,943 张来自自行重划分或转换, 应说明相对于引用版本的差异, 并保证所有自研消融使用同一划分。

严重性: Major **确定性:** 确定错误

M-02 实际启用的早停与平滑选模协议未披露

位置: 单流实现细节, 第 449–451 行。

问题: 论文只写“最多 100 轮、每轮验证、验证集选模”。实际论文运行启用了从第 20 轮开始的早停、patience=10、min-delta= 5×10^{-4} , 并以 5 次验证的移动平均作为早停判断; checkpoint 则按原始 segm AP 保存。随机种子 44 和确定性模式也未写入论文。

影响: 早停规则和“平滑指标用于停止、原始指标用于保存”的双重规则会改变训练时长与最终模型, 属于复现实验必须知道的协议。消融若未使用完全相同的规则, “只有提示模态和 P2 不同”的声明也无法验证。

建议修改: 在实现细节中补充完整的停止与选模规则, 并明确所有 WHU 主实验和消融是否共享 seed、早停规则和模型选择指标。若最终实验不采用早停, 则应在最终运行命令中关闭它并以最终清单为准。

严重性: Major **确定性:** 确定错误

M-03 P2 的边界机制缺少与核心主张直接对应的证据

位置: 贡献第 64 行; P2 方法第 212–272 行; 消融第 541、546 行; 讨论第 553–554 行。

问题: P2BoundaryRefiner 被定义为独立创新模块, 叙述重点是局部边界校准, 但最终证据只有 segm AP/AP₇₅。论文已经正确承认 AP₇₅ 不是边界指标, 不过这也意味着当前实验不能直接验证模块命名和机制主张。更值得注意的是, 当前第 41 轮 checkpoint 的验证集 P2-on/off 推理差异小于 10^{-5} , 训练日志中的 refined coarse Dice/IoU 也经常略低于 raw coarse; 这些诊断不能替代最终结果, 但提示必须提供更直接的机制验证。

影响: 即使最终 segm AP 提升成立, 审稿人仍可能认为收益来自额外训练参数或提示扰动, 而不是所声称的边界校准。

建议修改:在最终 checkpoint 上至少报告最终实例掩码的 Boundary F-score(明确容差)、Boundary IoU 或 trimap IoU, 并同时报告 raw/refined coarse mask 的 Dice、IoU 和边界指标。P2-on/off 应采用预先声明的训练协议; 若只做同一 checkpoint 的推理开关, 应明确其是干预诊断而不是训练消融。

严重性: Major 确定性: 证据不足

M-04累加式消融只能说明条件增量, 不能独立归因每个组件

位置:消融引言第 525 行; 论文表 V; 第 546 行。

问题:四行按 Point $\rightarrow$ Point+Box $\rightarrow$ Point+Box+Mask $\rightarrow$ Full 的固定顺序累加。该设计能估计“在已有组件条件下加入下一个组件”的增量, 却不能区分交互作用, 也不能说明 Box 或 Mask 在其他提示组合中的独立贡献。正文“isolate the contribution of each component”和“support the proposed component ordering”强于设计本身。

影响:提示模态高度相关, 固定顺序的单次差分容易被审稿人误读为独立因果贡献。

建议修改:将表名和正文改为“ordered/cumulative ablation”, 把结论限定为条件增量。若要主张独立贡献, 至少补充 Full-minus-Point、Full-minus-Box、Full-minus-Mask、Full-minus-P2 的逐项移除实验, 或采用完整/部分分析因设计并报告交互。

严重性: Major 确定性: 证据不足

M-05 WHU 跨论文比较的结果来源与复现行未逐行标记

位置:第 460 行及论文表 III。

问题:正文称表中同时包含“文献值”和“我们的 P2PFormer 复现”, 但表内没有符号区分哪些值来自原论文、哪些来自本地复现, 也没有给出 P2PFormer 复现的训练设置或运行方差。其余各行的具体六项数值是否由所引文献直接报告, 无法在不查外部论文的情况下确认。

影响:读者无法复核“最高”这一比较, 也无法判断表中不同方法是否使用完全相同的 WHU 实例划分, 尤其考虑到 M-01 中的划分冲突。

建议修改:在表注中逐行标注“reported”与“reproduced”, 对复现行给出统一数据划分、输入尺寸、checkpoint 选择和代码来源。最终逐一核对每个引文是否直接支持该行全部数值; 若协议不一致, 保留描述性比较但避免排名式结论。

严重性: Major 确定性: 需核对/确认

M-06 SynSU-Build 基线和双流结果缺少本地可复核实现闭环

位置:第 427、453–456、494–518 行; 双流方法第 320–412 行。

问题:论文声称在同一 SynSU-Build 划分上重训十个目标视角基线, 并给出完整双流结果, 但当前工作区中未找到与正文所述 3×3 offset retrieval、bbox/mask 双门控残差完全对应的双流实现、运行清单或各基线配置。现有 legacy_baseline 中的跨视角代码结构与论文公式并不相同, 不能直接作为这些数字的证据。

影响:数据集和双流模型是论文另外两项主要贡献; 缺少可追溯产物时, 论文表 IV 的公平性和方法公式均无法独立复核。

建议修改:明确最终双流代码所在版本和 commit, 保存每个基线及单/双流模型的配置、数据哈希、模型选择与测试清单。若代码位于当前工作区之外, 应在内部归档后再做一次逐公式实现审

计。

严重性: Major **确定性:** 需核对/确认

M-07 “21.8 instances/image” 的分母表述错误

位置: 数据集配置表, 第 180 行。

问题: 表格同一单元写 “9,000 RGB images; approx. 32.7k instances; 21.8 instances/image”。 $32.7k/9000 \approx 3.63$, 而 21.8 来自 $32.7k/1500$, 即每张有标注的目标视角图像。UAV 图像本身没有实例标注。

影响: 当前写法构成直接算术/分母歧义, 并可能让读者误以为 9,000 张图像都有实例标签。

建议修改: 改成 “21.8 target-view instances per scene group (equivalently, per annotated target image)”, 并避免使用无修饰的 “instances/image”。

严重性: Major **确定性:** 确定错误

Minor Issues

N-01 形态学算子的数学定义仍不足以精确复现

位置: 式 (eq:p2_support)-(eq:p2_loss_support), 第 214–260 行; 式 (eq:point_mining_score), 第 275–281 行。

问题: ∂ 、 Dilate_k 、 $\mathcal{D}_{\text{morph}}$ 和 $\max(R_r, T_r)$ 没有明确结构元素、边界填充和逐元素语义。代码使用零填充的 3×3 方形膨胀/腐蚀, k 表示按 Chebyshev 邻域扩张的像素半径; $\max$ 为逐元素最大值。另一方面, 平滑平均采用 replicate padding。

影响: 不同形态学库的圆形/十字/方形结构元素及边界处理会生成不同支持带, 尤其影响贴近 ROI 边缘或全前景粗掩码的样本。

建议修改: 在方法中用一句话统一定义这些算子, 并指出平均池化使用 replicate padding, 而形态学边界将 ROI 外视为背景。

严重性: Minor **确定性:** 疑似问题

N-02 coarse loss 公式的批次归约和 ϵ 未显式定义

位置: 式 (eq:coarse_loss), 第 301–308 行。

问题: 公式保留了 ROI 索引 r , 却写成单 ROI 标量, 之后仅以文字说 “averaged over candidate instances”; BCE 的像素归约和 ϵ 数值也未给出。代码是全元素 mean BCE, 加上逐 ROI Dice loss 后再对 ROI 取 mean, 平滑项默认为实现配置值。

影响: 这不会改变当前结论, 但会妨碍公式与代码的一一对应, 并在 ROI 尺寸或 batch 组成改变时产生归约歧义。

建议修改: 写成显式的 $|\mathcal{R}|^{-1} \sum_{r \in \mathcal{R}}$ 形式, 分别定义像素 mean BCE 和逐 ROI Dice, 并给出 ϵ 。

严重性: Minor **确定性:** 疑似问题

N-03 Place 隐藏了会影响提示值的量化细节

位置: 式 (eq:dense_canvas) 及第 283–295 行。

问题: 论文只称其为“bounded raw-logit preprocessing followed by bilinear resize-and-rasterization”。实际论文运行对 logit 截断到 $[-8, 8]$ ，将 box 缩放到 PromptEncoder 原生 mask canvas 后对左上角取 floor、右下角取 ceil，box 外填 0，再双线性插值。当前数学定义无法唯一确定这些操作。

影响: box 边缘量化和外部填充值会改变 PromptEncoder 的 dense embedding，属于实现面对公式的重要边界条件。

建议修改: 在实现细节或附录中给出 clamp 范围、canvas 尺寸来源、floor/ceil 规则及 box 外填充值；主文可保持简洁，但应提供可定位的完整定义。

严重性: Minor **确定性:** 确定错误（公式不完备，不是前向实现错误）

N-04 评估符号 P 与特征金字塔 P_2 – P_6 重名

位置: 总体架构第 199 行；评估公式第 431–438 行。

问题: 方法中 P_l 表示 PAFPN 层，评估中又用 P 表示 prediction。局部上下文能够区分，但全文符号表中会形成不必要的重载。

影响: 对公式较密集的稿件，这会增加读者在 P_2 与预测集合之间切换的认知成本。

建议修改: 将评估预测改记为 $\hat{G}$ 、 $\mathcal{P}$ 或 M^{pred} ，或在评估小节明确说明该符号仅局部使用。

严重性: Minor **确定性:** 疑似问题

N-05 参考文献存在两个未使用条目

位置: 参考文献中的 ref_sam 与 ref_samassist。

问题: 两个 bibitem 未在正文引用；所有实际使用的 citation key 均已定义，交叉引用也未发现 undefined 或 multiply-defined 问题。

影响: 不影响科学结论，但会造成参考文献卫生问题，也可能暗示相关工作删改后遗留。

建议修改: 删除未使用条目，或在确有必要的位置加入有实质作用的引用，不要仅为保留条目而堆引用。

严重性: Minor **确定性:** 确定错误

Writing Suggestion

W-01 将外部比较中的“最高”进一步降格为表内描述

位置: 第 491 行。

问题: 当前句子已说明协议异质，但“has the highest”仍容易在摘要式阅读中被截取为严格 SOTA 结论。

影响: 在 M-01 和 M-05 未解决前，排名语气会放大可比性风险。

建议修改: 使用“among the heterogeneous values collected in Table II”或“the largest listed value”并紧邻协议限定；最终逐行核验后再决定是否保留更强措辞。

严重性: Writing Suggestion **确定性:** 证据不足

高优先级修改顺序

1. 完成并冻结主实验与每个消融实验，生成可追溯测试清单，再回填全文数字。

2. 统一 WHU 标注文件与 2,943/627/2,220 实际划分，并补全早停、选模和随机种子协议。
3. 为 P2 增加最终 mask 边界指标和 raw/refined coarse 诊断，避免只靠 AP₇₅ 讲边界故事。
4. 将累加式消融明确解释为条件增量；若篇幅和算力允许，再补逐项移除实验。
5. 归档 SynSU-Build 所有基线与双流模型的实现和运行清单，并对外部表格逐行核对来源。

需核对/确认事项

- 论文表 I 中每个数据集关于 S-U pairing、Multi-UAV、 K/T 和实例标注的勾选状态，需要回看原始论文或官方文档逐项确认。
- “Among representative datasets, none combines ...” 及 “To our knowledge” 属于有限检索后的新颖性主张，需要正式文献检索记录支持。
- 论文表 III 全部外部方法的六项数值、数据划分和训练协议，需要逐篇核对；尤其应区分原文报告值和本地复现值。
- 2026 年文献条目（如 RS4D、UniGeoRS）的最终出版信息、页码和题名需要在投稿前查证。
- 双流公式与最终代码尚需在实现归档后单独做代码级审计；本报告只确认其内部符号链基本自洽，未能确认与最终实现完全一致。

编译与静态检查

`main5.tex` 可由 `latexmk -pdf` 成功编译；日志中没有未定义引用、未定义 citation 或重复 label，仅有少量 Underfull box 排版提示。已按 skill 要求运行 `scripts/proofing_scan.py`；命中的 semicolon-capitalization 候选均为正常句法或表格缩写，没有形成新增实质 finding。全文表格差值核算未发现算术错误，除 M-07 所述分母标签问题外。